

# Natural Language Processing and Computational Linguistics

<http://www.acornpub.co.kr/book/nlp-computational-linguistics>

문서의 요약과 자동 인코딩

기계 번역

마이크로소프트 사의 텍스트 분석 API

매트랩

파이썬 생태계에서 사용할 수 있는 다양한 패키지를 제공하는 것을 생각해보면 파 이썬은 텍스트 분석 영역에서 선두를 달리고 있다고 볼 수 있으며, 그렇기 때문에 우리는 이를 사용하는 데 집중할 필요가 있다. 매우 강력하고 활발한 오픈 소스 커 뮤니티가 그 매력을 더한다.

미국 국립 말뭉치 / 영국 국립 말뭉치 / 브라운 말뭉치

Beautiful Soup / urllib / scrape (+ twitter의 tweepy)

가비지 입력, 가비지 출력 : GIGO

'Pastiche detection based on stopword rankings. Exposing impersonators of a Romanian writer'

레타마이징, 스테밍

순환 신경망, 합성곱 신경망

텐서플로, 사이킷런, 큐오라 Quora

파이썬

텍스트 출력 및 조작

문자열 조작

파이썬으로 문자열 조작

파이썬으로 텍스트 처리하기

파이썬으로 하는 텍스트 분석 소개

스파이시

맷 호니발

장점

1. 비파괴적 토큰화 ~ 품사 토큰화
2. 1개 이상의 언어 지원
3. 5개 언어에 대한 6개 통계 모델
4. 사전 학습된 워드 벡터
5. 간편한 딥러닝 통합
6. 품사 태깅
7. NER ~ 객체명
8. 레이블 의존 구문 분석
9. 구문 기반 문장 분리
10. 구문과 NER을 위한 내장 시각화 도구
11. 편리한 문자열 해시 매핑
12. 넘파이 데이터 배열 변환
13. 효과적인 이진 직렬화 binary serialization
14. 간편한 모델 패키지 및 배포
15. 최고의 처리 속도
16. 강건하고 엄격히 측정된 정확도

젠심

메모리 독립성, 잠재 의미 분석, LDA, 랜덤 투영, HDP, Word2vec

역할 벡터

BOW 모델

TF-IDF

워드 벡터

N-그램

품사 태깅

- 명사, 동사, 형용사, 부사, 대명사 전치사, 접속사

partofspeech.org

은닉 마르코프 모델

음성 인식과 기계 번역

NLTK

NER : Named Entity Recognition

NED : Named Entity Disambiguation

CRF : Conditional Random Fields

스탠퍼드 개체명 테거

청킹

www.wired.com

의존 구문 분석

지역 구문 분석

토픽 모델링

동적 토픽 모델링

잠재 디리클레 할당

잠재 의미 색인

HDP

LDA

음수 미포함 행렬 분해

어간 추출

표제어 추출

튜닝 파라미터 : chunks, passes, iterations

하이퍼 파라미터 : alpha, beta, number of topic

문서 탐색

주제 일관성  
토픽 모델 시각화  
LDAvis

텍스트 군집화  
TfidfVectorizer  
주성분 분석 : PCA  
빈도수 벡터화  
특이값 분해  
K-평균  
계층적 군집화  
워드 메서드  
나이브 베이즈 분류, 서포트 벡터 머신

유사도 매트릭스  
헬링거 함수  
쿨백 라이블러 발산 함수  
자카드 지수  
유사 질의

워드 임베딩  
Word2Vec  
시보우(CBOW) 모델  
스킵 그램 모델  
Doc2Vec  
글로브  
패스트텍스트  
워드랭크  
바임베드

푸앵카레

딥러닝

바닐라 신경망

이미지 캡션화

강화학습

케라스

스파이시

딥 뉴럴 네트워크

감정 분석

TextBlob

레딧