

Developing elegant AI these days

<https://product.kyobobook.co.kr/detail/S000216064274>

깃허브 코파일럿

- 인라인 채팅 / 사이드바 채팅
- 앱 스캐폴딩하기 : 라이브러리 버전 명시하기
- 워크스페이스 구조 설명 요청하기
- 함수명 잘 짓기, 주석 작성하기, 모듈 먼저 가져오기, GIGO, 관련있는 파일 열어두기, 슬래시 명령어로 요청 종류 알려주기, 챗 변수 활용하기, 챗 참가자 명시하기, 사용자 지정 지침 설정하기

GIT FLOW

- GIT 브랜치 전략, 백포팅 전략
- 프롬프팅을 완벽한 맥락 전달 어려움, 할루시네이션

프롬프트 일반화

응답 최적화

프롬플 구조와 형식 개선

하이브리드 접근의 필요성

- 저작권, 상표권, 초상권 정책 등 아직 사람의 손 필요

AI 성격 정의 → 알맞은 학습 교재 제공 → 훈육

실시간 반응형 추천 시스템

- 실시간 행동 이력 스트리밍 ~ 조회

벡터 유사도 검색

밀버스

레디스 스택

모옥 디비 아틀라스 서치

오픈서치

로커스트

체계화

효율화

접근성

자동화

LLM

RAG

LLMOps

<https://techblog.woowahan.com/18144/>

<https://techblog.woowahan.com/18362/>

데이터 카탈로그

로그 체커

싱글턴

가이드드 싱글턴

멀티턴

폴라스

<https://pola.rs>

- IO 기능
- Lazy API 와 쿼리 최적화
- 아웃 오브 코어 방식 (스트리밍 API)

서빙 컴포넌트

- 파이토치, 텐서플로, 캐부슬, 사이킷 런

CI

- 이미지 생성 자동화

CD

- 서빙 자동화

Keeepalive

API 게이트웨이

실험적 피드백

LLM 서빙

프롬프트 실험

하이브리드 검색

RAG 파이프라인

신경망 처리 장치, NPU

구글 텐서 처리 장치, TPU

인텔 비전 처리 장치, VPU

엔비디아 딥러닝 가속기, DLA

TensorRT

- 양자화
- 그래프 최적화
- 커널 자동 튜닝
- 동적 텐서 메모리
- 다중 스트림 시행

ONNX 모델

Polygraphy

양자화 인식 훈련, QAT

훈련 후 양자화, PTQ

가짜 양자화, Q/DQ

torch.ao.quantization

pytorch-quantization

에지 파이프라인

Trtexec

TREx

Nsight Systems